Preparado para: AT autoridade tributária e aduaneira

REFORM/SC2022/126
DELIVERABLE 4

MÓDULO 2
GESTÃO E TRATAMENTO DE DADOS EM R

DESIGNING A NEW VALUATION MODEL
FOR RURAL PROPERTIES IN PORTUGAL

Parte I

Formador: Luís Teles Morais | Nova SBE

Lisboa, 5 maio 2023

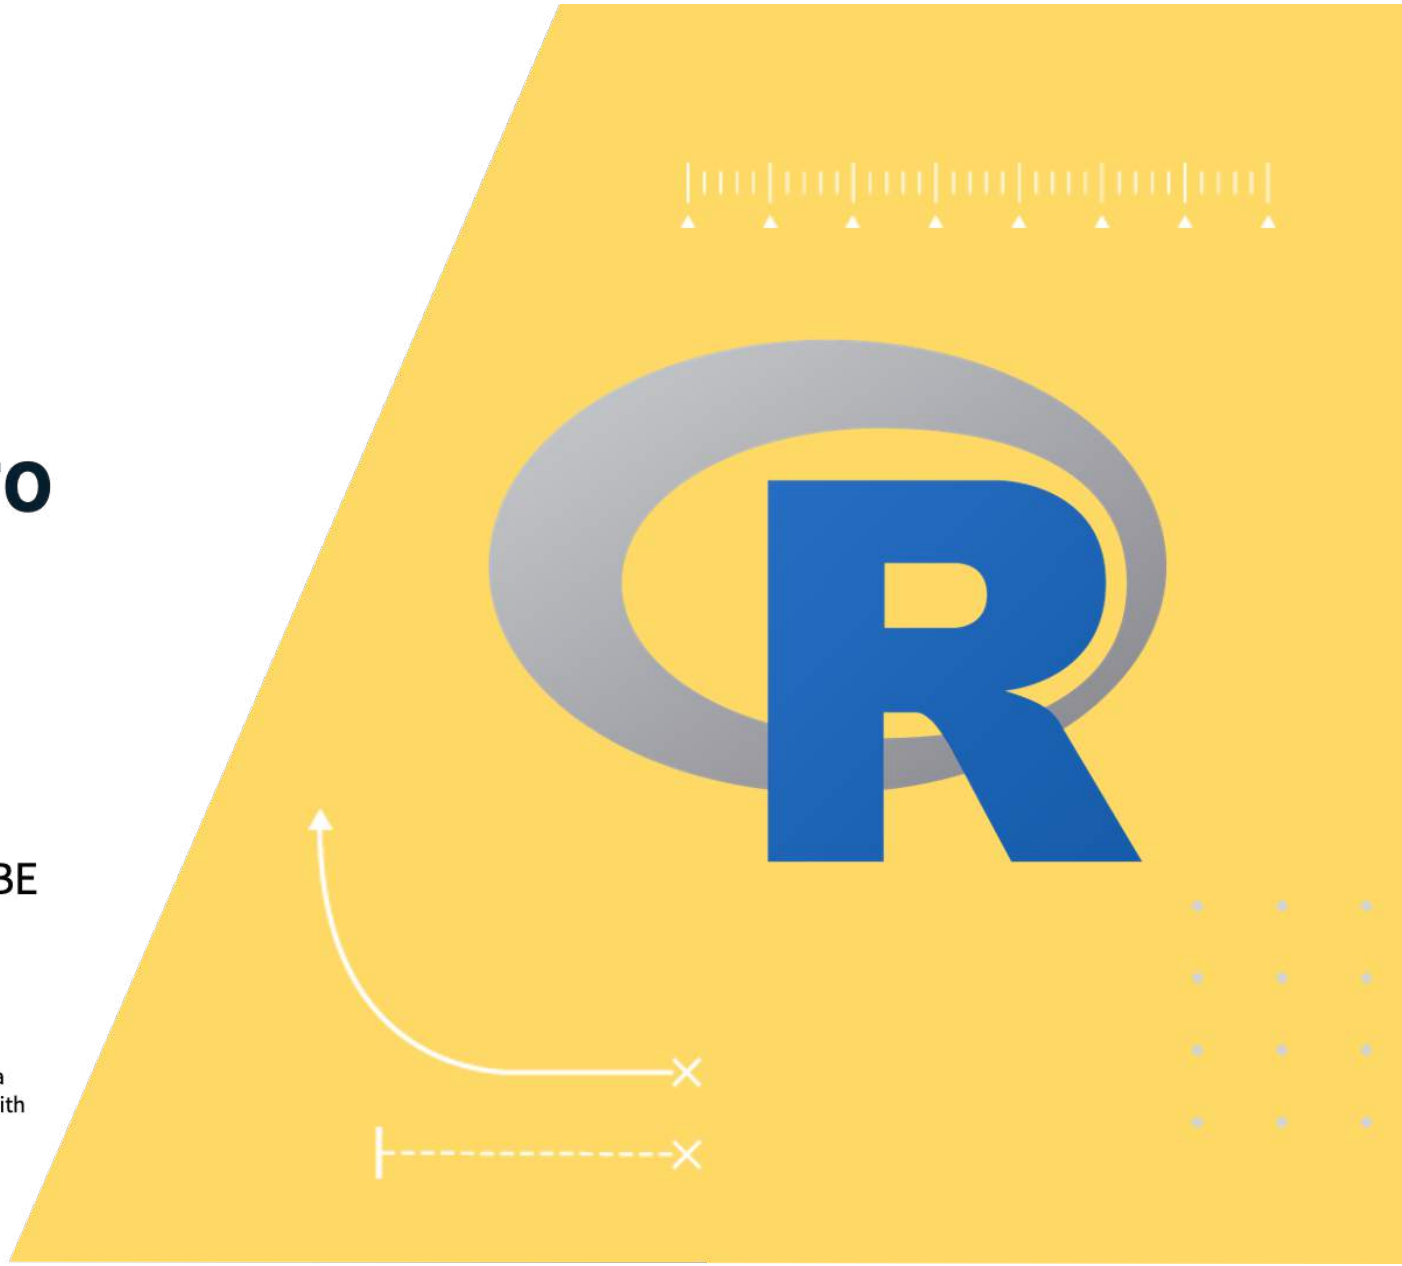

This project is carried out with funding by the European Union via the Structural Reform Support Programme and in cooperation with the Directorate General for Structural Reform Support of the European Commission

AARC NOVA SCHOOL OF BUSINESS & ECONOMICS LOBO VASQUES esri INNERLANDS

Programa

Módulos	Duração
Módulo 1 – Introdução ao R: - O que é o R? - Como instalar e configurar o R. - Sintaxe básica e comandos. - Tipos de dados, objetos e classes.	**4 Horas**
Módulo 2 – Gestão e tratamento de dados em R: - Carregar dados no R. - Perceber as estruturas de dados e *subsetting*. - Limpeza de dados: *missing values, outliers* e transformações - Juntar bases de dados	**8 Horas**
Módulo 3 – Estatística básica em R: - Estatísticas descritivas: medidas de dispersão central e variação. - Distribuições probabilísticas: variáveis discretas e contínuas. - Testes de hipóteses.	**8 Horas**

Módulos	Duração
Módulo 4 – Regressão Linear: - O modelo classico linear. - Estimação de parametros segundo o MMQ. - Testes de hipóteses: significância estatística e ajuste do modelo. - Modelo de regressão múltipla. - Testar as premissas: multicolinearidade, heteroscedasticidade e normalidade dos resíduos. - Critérios de seleção dos modelos.	**12 Horas**
Módulo 5 – O modelo: - Estrutura do modelo e premissas – Perceber o modelo (4 Hours). - Uso e tratamento dos dados (4 Hours). - Descrição do modelo (4 Hours). - Aplicação do modelo a cada piloto (12 Hours). - Aplicação autónoma do modelo a uma região (8 Hours).	**32 Horas**

Vamos a isso

Aceda a este link para começar já

https://posit.cloud/content/5906356

Quiz 1

slido.com

#3915775

Importar dados no R

Ciência de dados

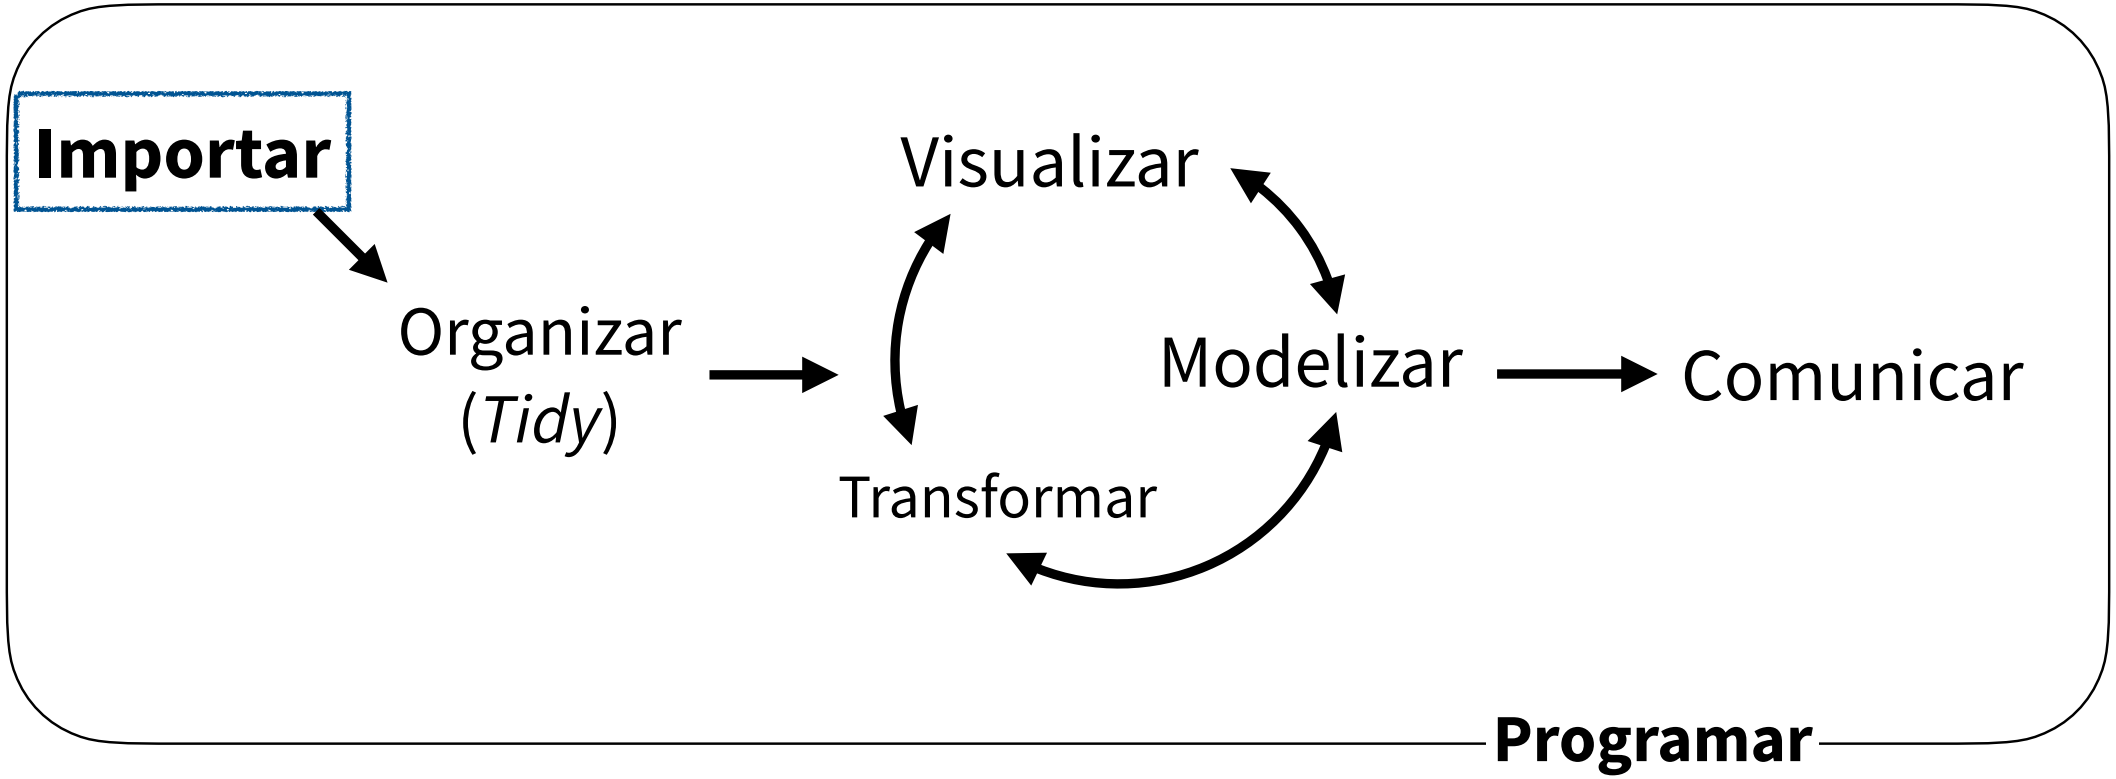

babynames.csv

Nomes e sexo dos bebés nascidos nos EUA de 1880 a 2017. 1.9M de observações.

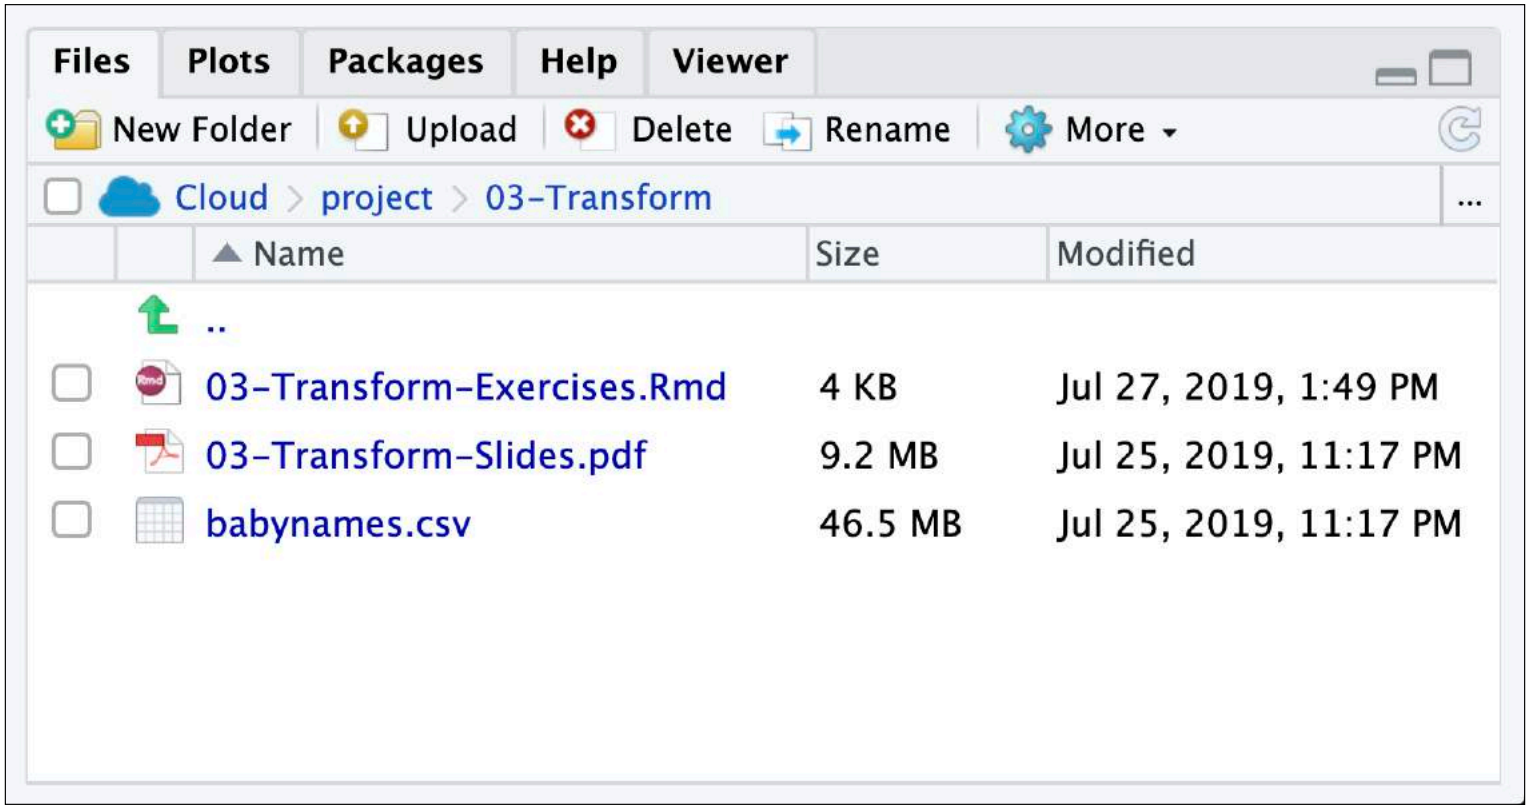

babynames.csv

```
year,sex,name,n,prop
1880,F,Mary,7065,0.07238359
1880,F,Anna,2604,0.02667896
1880,F,Emma,2003,0.02052149
1880,F,Elizabeth,1939,0.01986579
1880,F,Minnie,1746,0.01788843
1880,F,Margaret,1578,0.0161672
1880,F,Ida,1472,0.01508119
1880,F,Alice,1414,0.01448696
```

babynames.csv

```
year,sex,name,n,prop
1880,F,Mary,7065,0.07238359
1880,F,Anna,2604,0.02667896
1880,F,Emma,2003,0.02052149
1880,F,Elizabeth,1939,0.01986579
1880,F,Minnie,1746,0.01788843
1880,F,Margaret,1578,0.0161672
1880,F,Ida,1472,0.01508119
1880,F,Alice,1414,0.01448696
```

Importar

Import Dataset From Text (readr)…

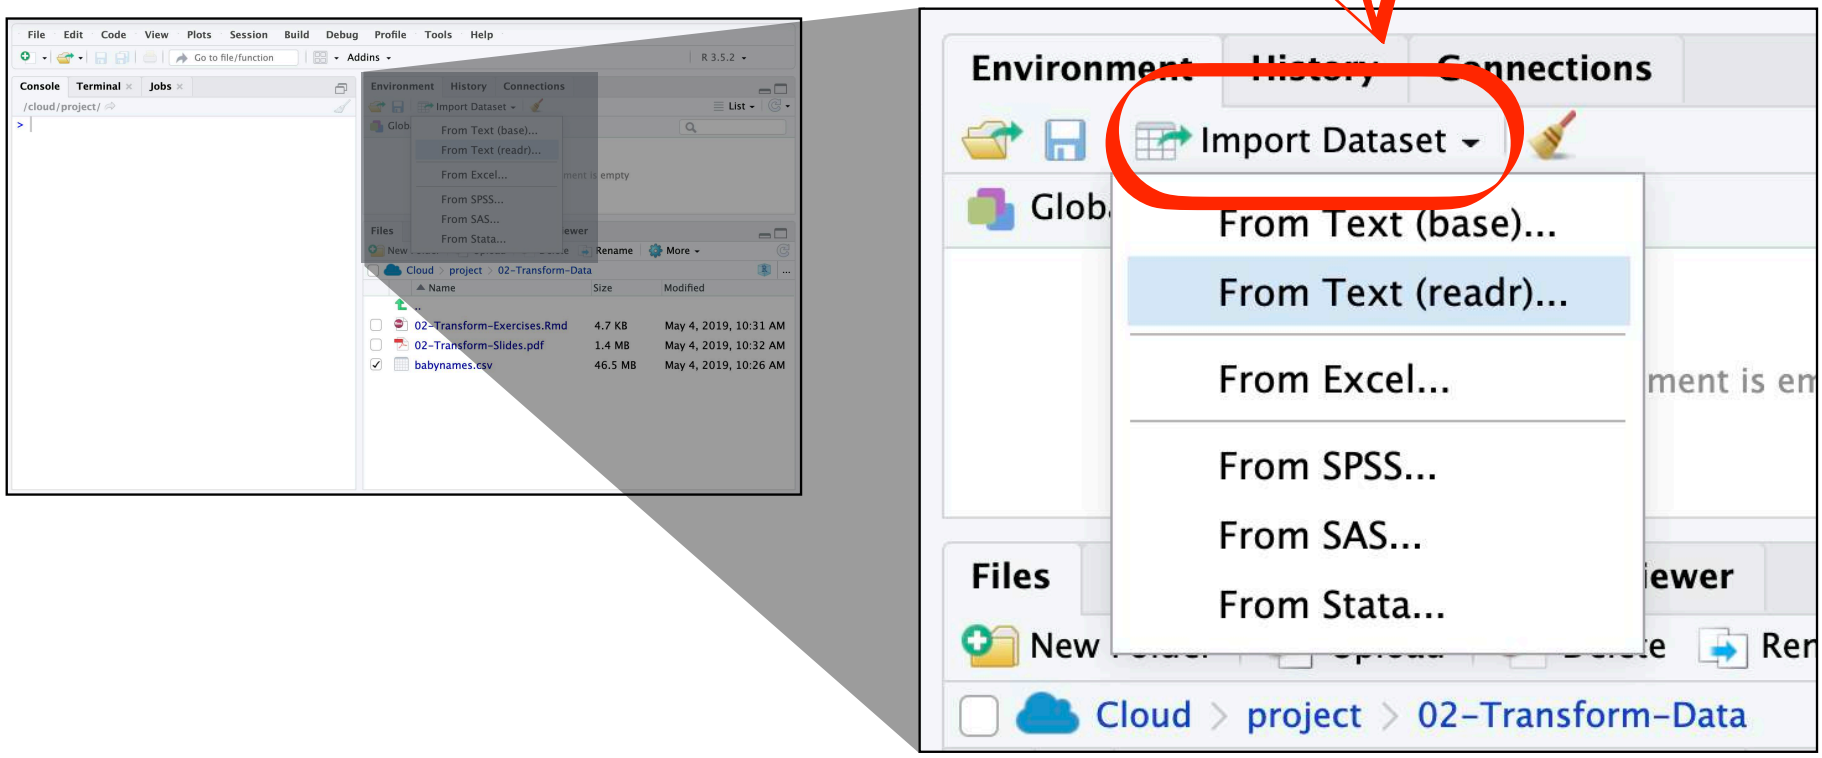

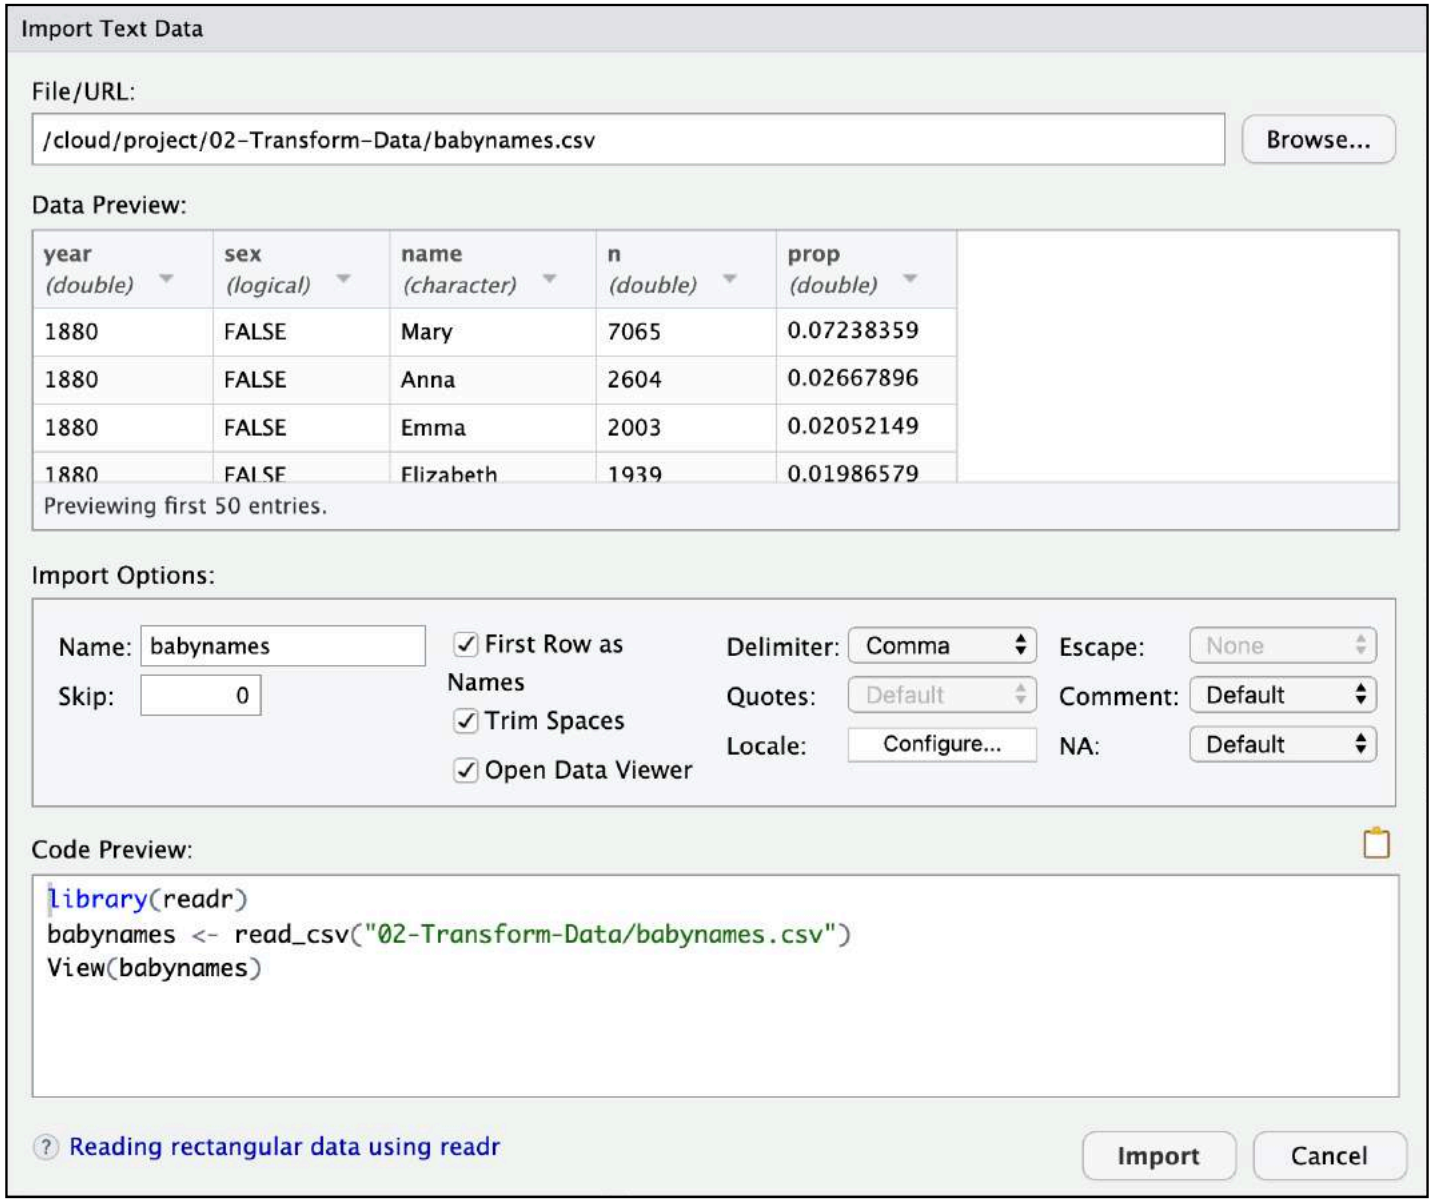
Import Text Data
File/URL:
/cloud/project/02-Transform-Data/babynames.csv
Browse...
Data Preview:
year (double)
sex (logical)
name (character)
n (double)
prop (double)
1880 FALSE Mary 7065 0.07238359
1880 FALSE Anna 2604 0.02667896
1880 FALSE Emma 2003 0.02052149
1880 FALSE Elizabeth 1939 0.01986579
Previewing first 50 entries.
Import Options:
Name: babynames
Skip: 0
First Row as Names
Trim Spaces
Open Data Viewer
Delimiter: Comma
Quotes: Default
Locale: Configure...
Escape: None
Comment: Default
NA: Default
Code Preview:
library(readr)
babynames <- read_csv("02-Transform-Data/babynames.csv")
View(babynames)
Reading rectangular data using readr
Import
Cancel

babynames

year <dbl>	sex <chr>	name <chr>	n <dbl>	prop <dbl>
1880	F	Mary	7065	0.07238359
1880	F	Anna	2604	0.02667896
1880	F	Emma	2003	0.02052149
1880	F	Elizabeth	1939	0.01986579
1880	F	Minnie	1746	0.01788843
1880	F	Margaret	1578	0.01616720
1880	F	Ida	1472	0.01508119
1880	F	Alice	1414	0.01448696
1880	F	Bertha	1320	0.01352390
1880	F	Sarah	1288	0.01319605

1–10 of 1,924,665 rows Previous 1 2 3 4 5 6 ... 100 Next

! !

Transformação de dados (II)

Estruturar e filtrar

Percentagem de recém-nascidas com o nome Maria 🇵🇹 nos EUA 🇺🇸

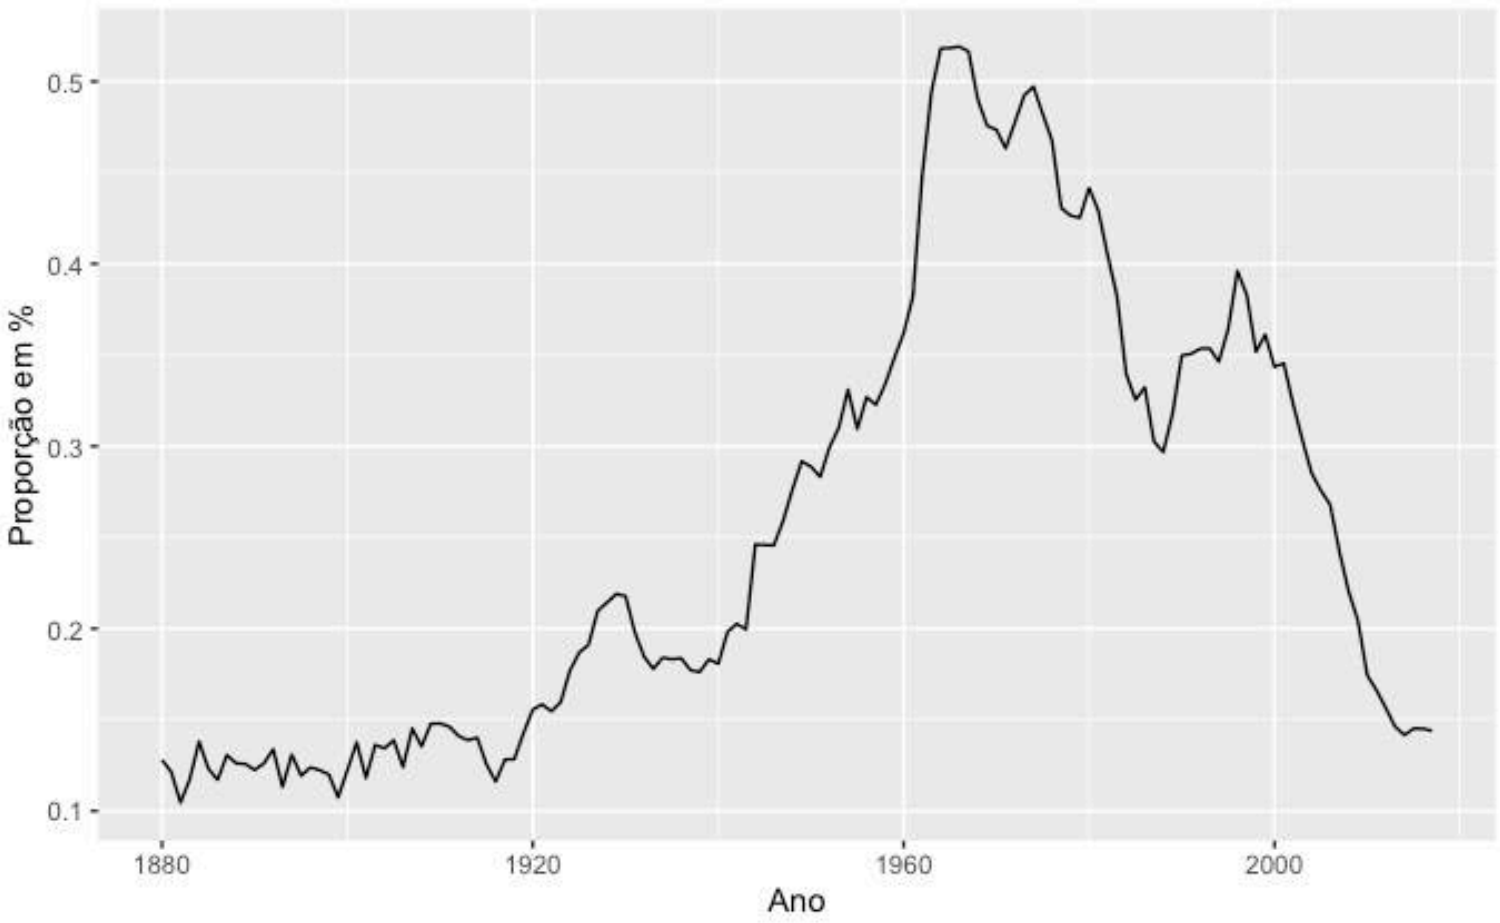

Ciência de dados

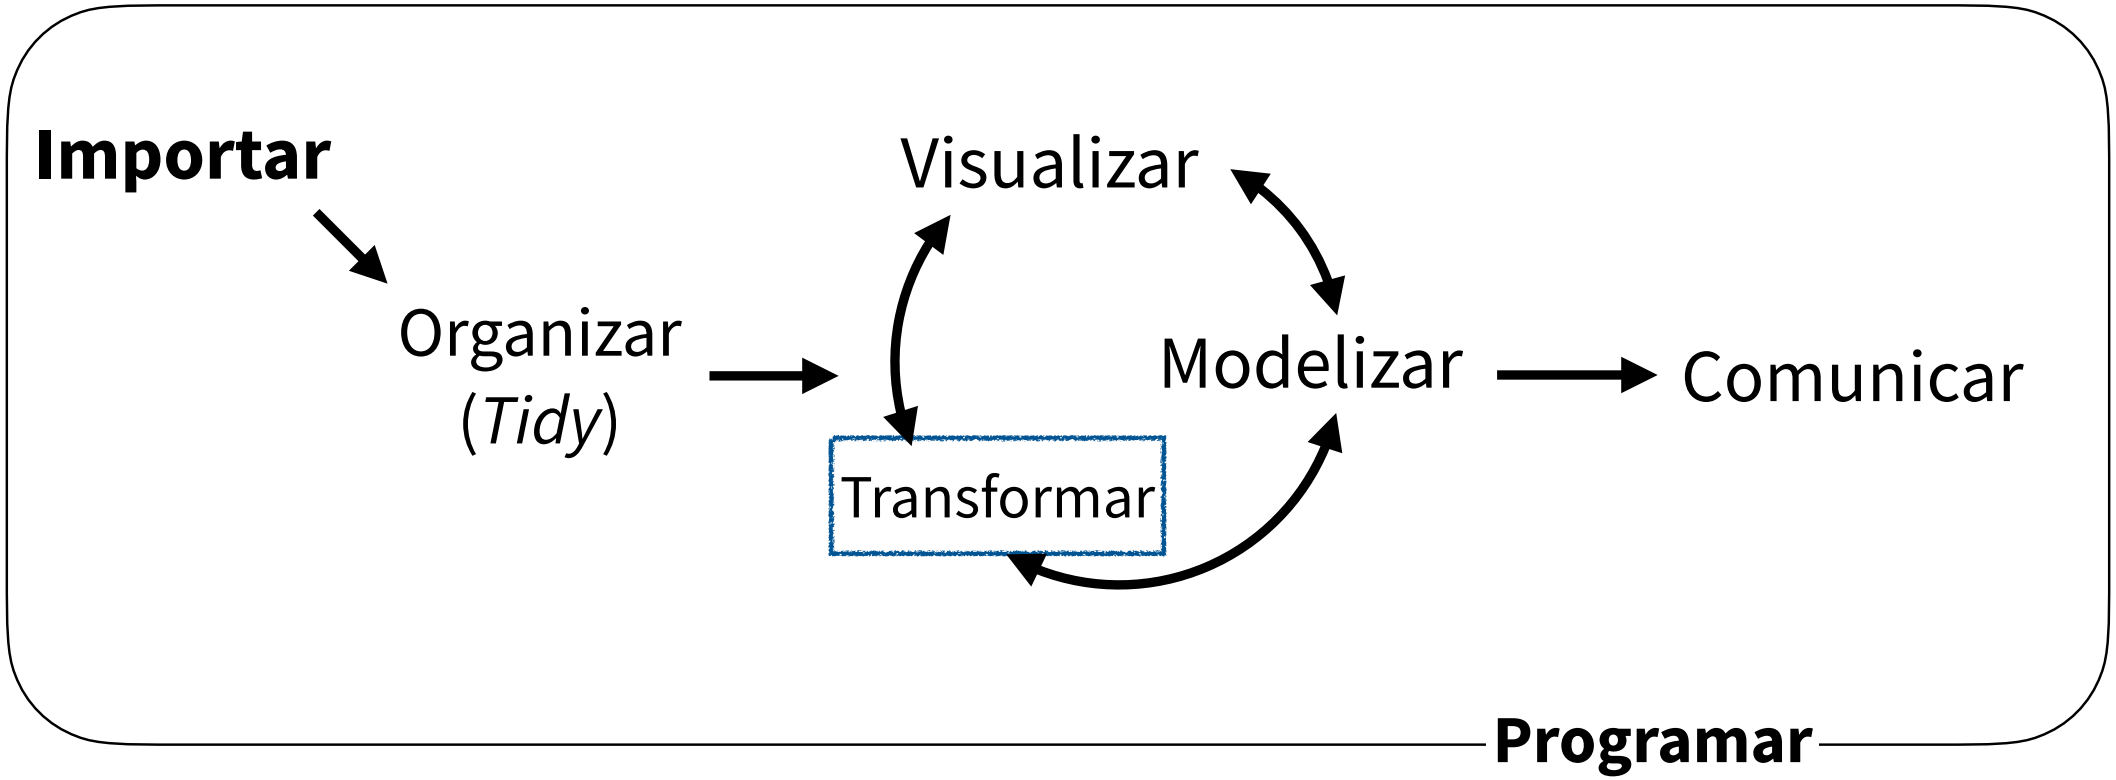

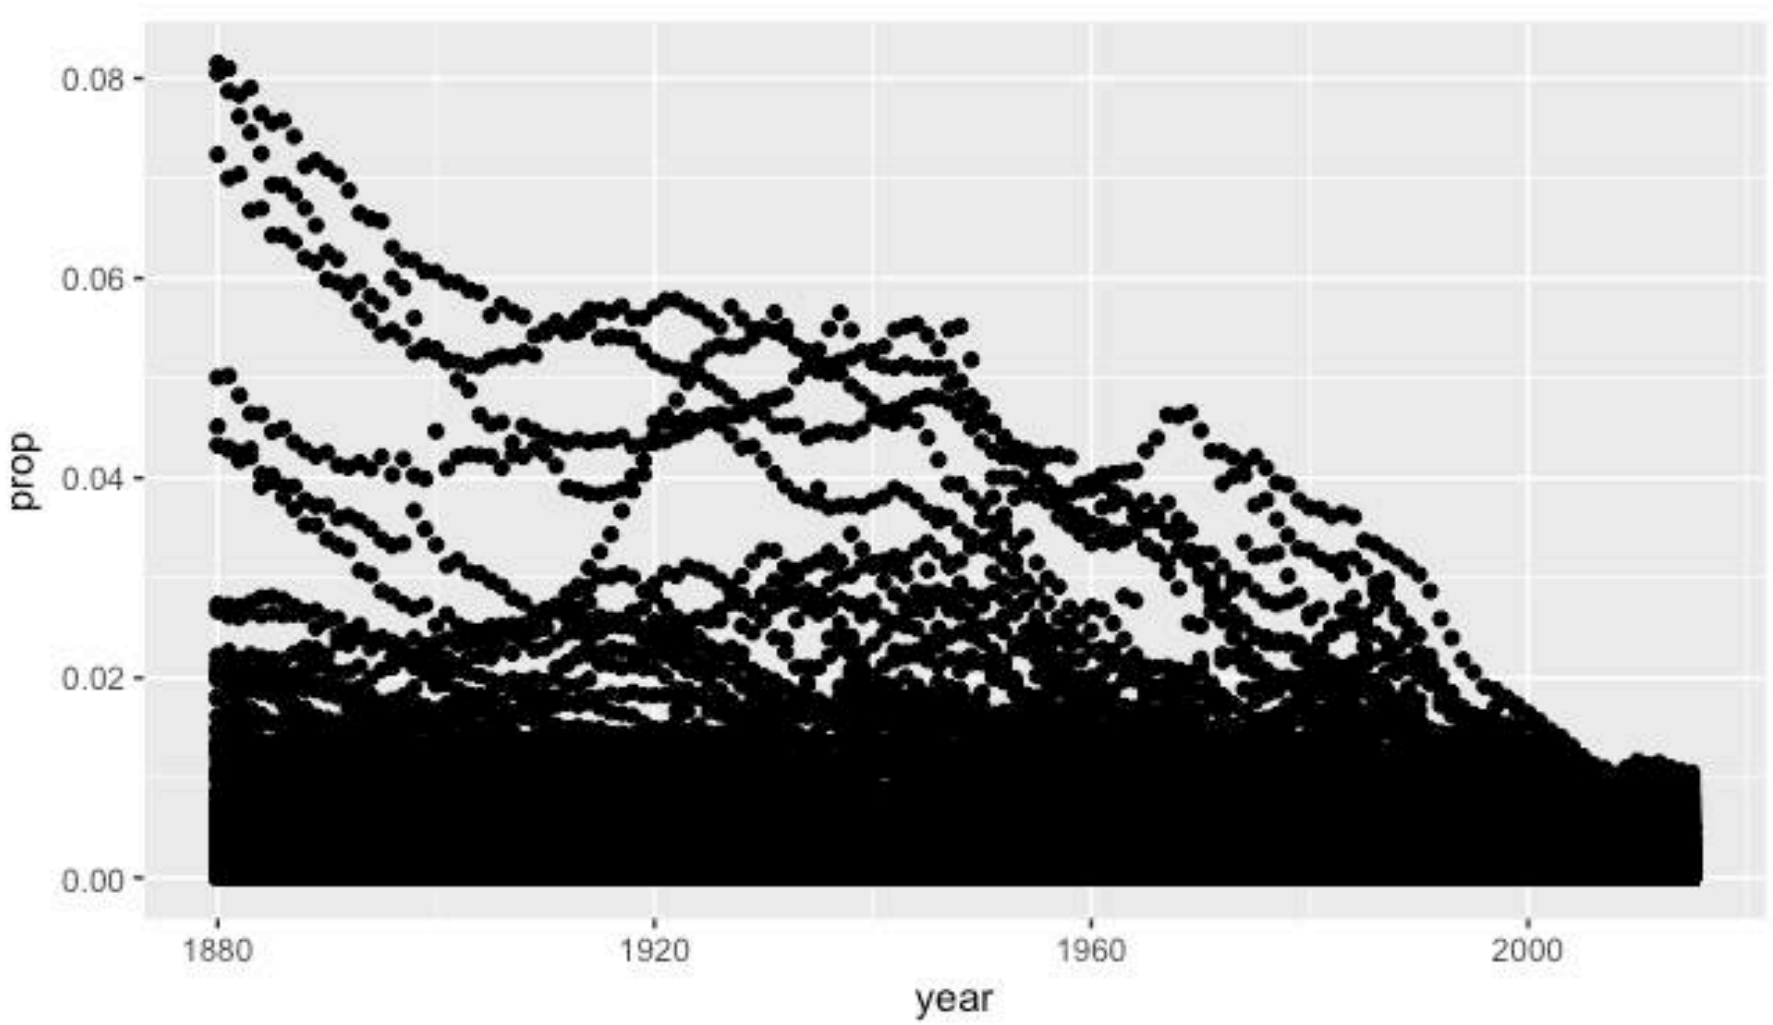


```
ggplot(data = babynames) +
  geom_point(mapping = aes(x = year, y = prop))
```

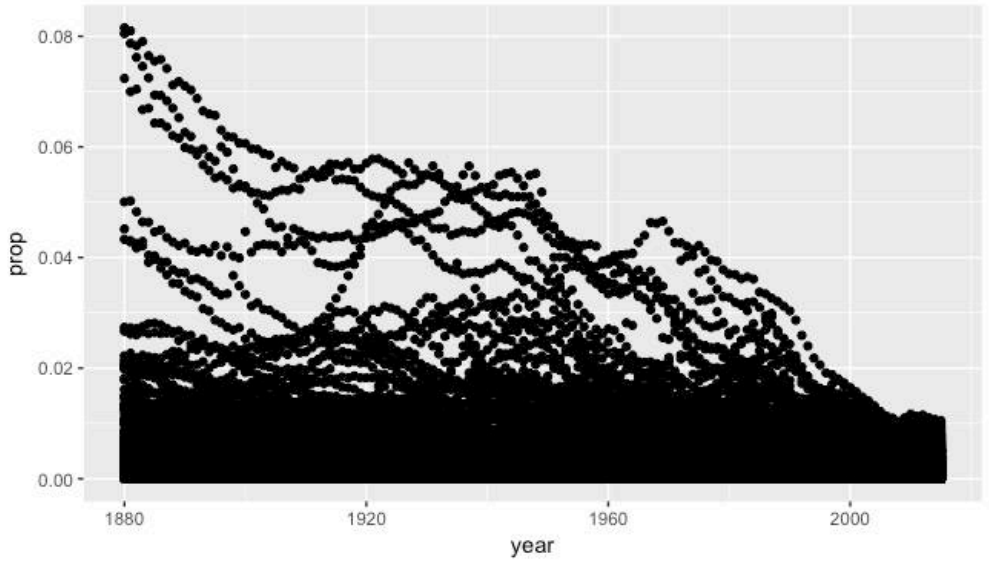
0.08
0.06
0.04
0.02
0.00
prop
1880
1920
1960
2000
year

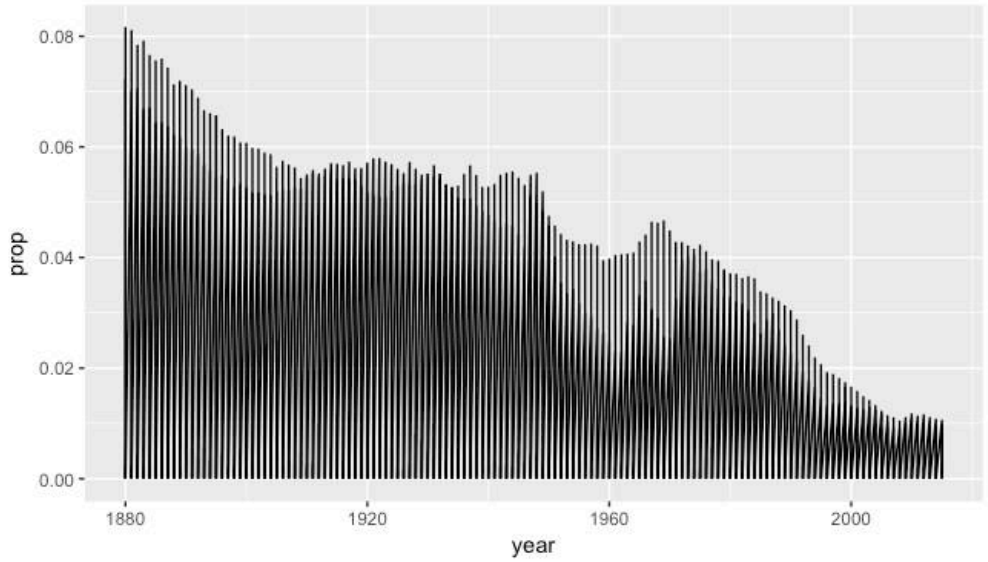
0.08
0.06
0.04
0.02
0.00
prop
1880
1920
1960
2000
year

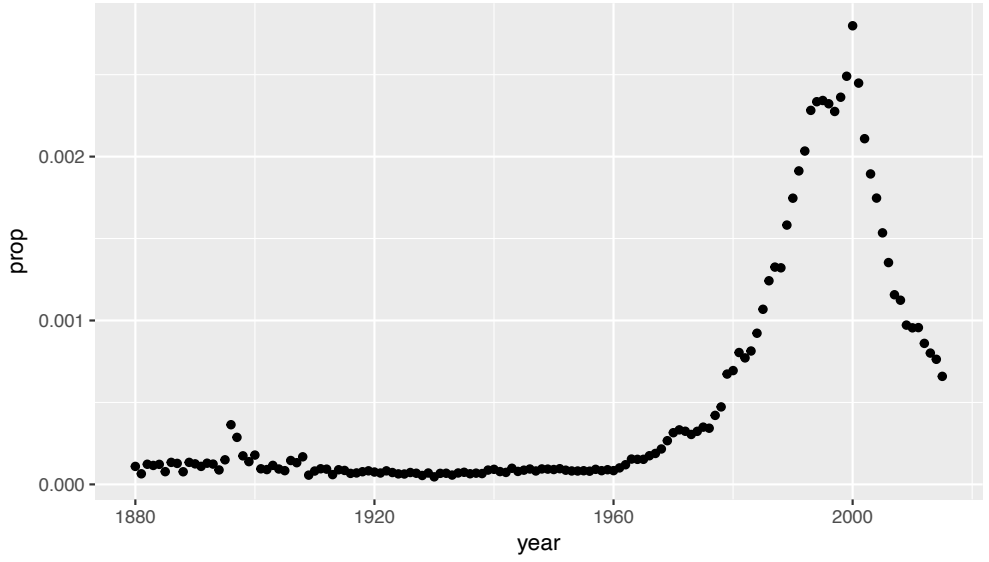
0.002
0.001
0.000
prop
1880
1920
1960
2000
year

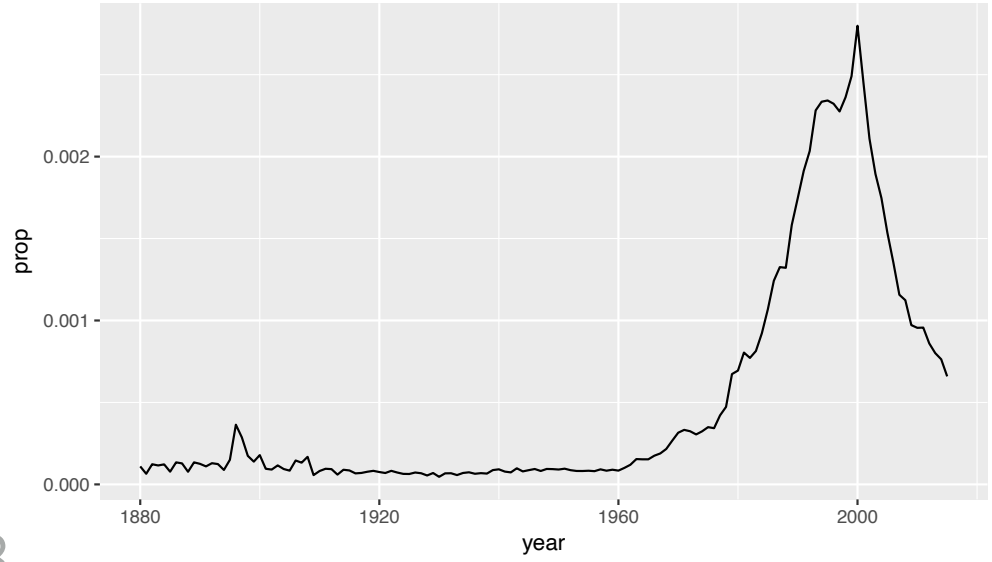
0.002
0.001
0.000
prop
1880
1920
1960
2000
year

Como isolar as observações de interesse?

	year	sex	name	n	prop
1	1880	F	Mary	7065	0.0724
2	1880	F	Margar	1578	0.0162
3	1880	F	Martha	1040	0.0107
4	1880	F	Marie	471	0.00483
5	1880	F	Maria	125	0.00128
1	1881	F	Mary	6919	0.0700
2	1881	F	Margar	1658	0.0168
3	1881	F	Martha	1044	0.0106
4	1881	F	Marie	499	0.00505
5	1881	F	Maria	120	0.00121
	1881	M	Gideon	7	0.0001

year	sex	name	n	prop
1880	F	Maria	125	0.00128
1881	F	Maria	120	0.00121
…	…	Maria	…	…

Subsetting - subconjuntos de interesse

select() - extrair **variáveis**
filter() - extrair **observações**
arrange() - reordenar **observações**

select()

Extrair determinadas variáveis (colunas)

```
select(.data, …)
```

conjunto de dados a transformar (data.frame/tibble)

nome das variáveis a extrair (ou função que selecione variáveis)

select()

Extrair determinadas variáveis (colunas)

```
select(babynames, name, prop)
```

babynames

year	sex	name	n	prop
1880	M	John	9655	0.0815
1880	M	William	9532	0.0805
1880	M	James	5927	0.0501
1880	M	Charles	5348	0.0451
1880	M	Garrett	13	0.0001
1881	M	John	8769	0.081

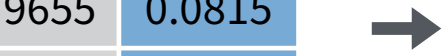

name	prop
John	0.0815
William	0.0805
James	0.0501
Charles	0.0451
Garrett	0.0001
John	0.081

Como selecionar a coluna **n**?

Como selecionar a coluna **n**?

```
select(babynames, n)
```

```
select(babynames, n)
#       n
#    <int>
# 1   7065
# 2   2604
# 3   2003
# 4   1939
# 5   1746
# …    …
```

Que tipo de objeto é este?

select()

Extrair determinadas variáveis (colunas)

```
select(babynames, n)
```

babynames

year	sex	name	n	prop
1880	M	John	9655	0.0815
1880	M	William	9532	0.0805
1880	M	James	5927	0.0501
1880	M	Charles	5348	0.0451
1880	M	Garrett	13	0.0001
1881	M	John	8769	0.081

n
9655
9532
5927
5348
13
8769

$

Extrair *conteúdo* de uma variável (como um vector)

```
babynames$n
```

babynames

year	sex	name	n	prop
1880	M	John	9655	0.0815
1880	M	William	9532	0.0805
1880	M	James	5927	0.0501
1880	M	Charles	5348	0.0451
1880	M	Garrett	13	0.0001
1881	M	John	8769	0.081

→ 9655 9532 5927 5348 …

$

Extrair *conteúdo* de uma variável (como um vector)

```
babynames$n
```

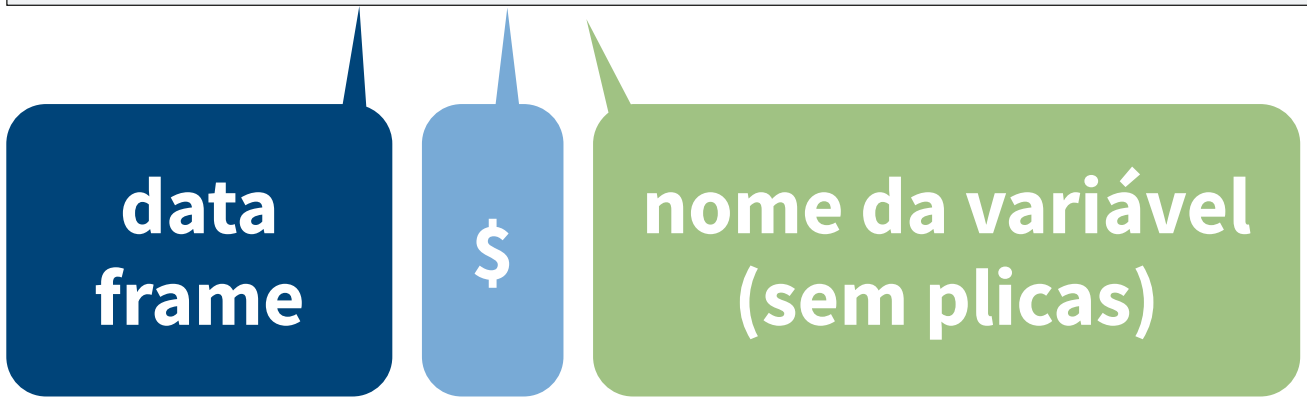

select() helpers - seleção de variáveis

: - Selecionar intervalo de várias colunas

```
select(mpg, cty:class)
```

- - Todas as colunas exceto

```
select(mpg, -c(cty, hwy))
```

starts_with() - Colunas cujo nome começa por...

```
select(mpg, starts_with("c"))
```

ends_with() - Colunas cujo nome acaba em...

```
select(mpg, ends_with("y"))
```

etc.

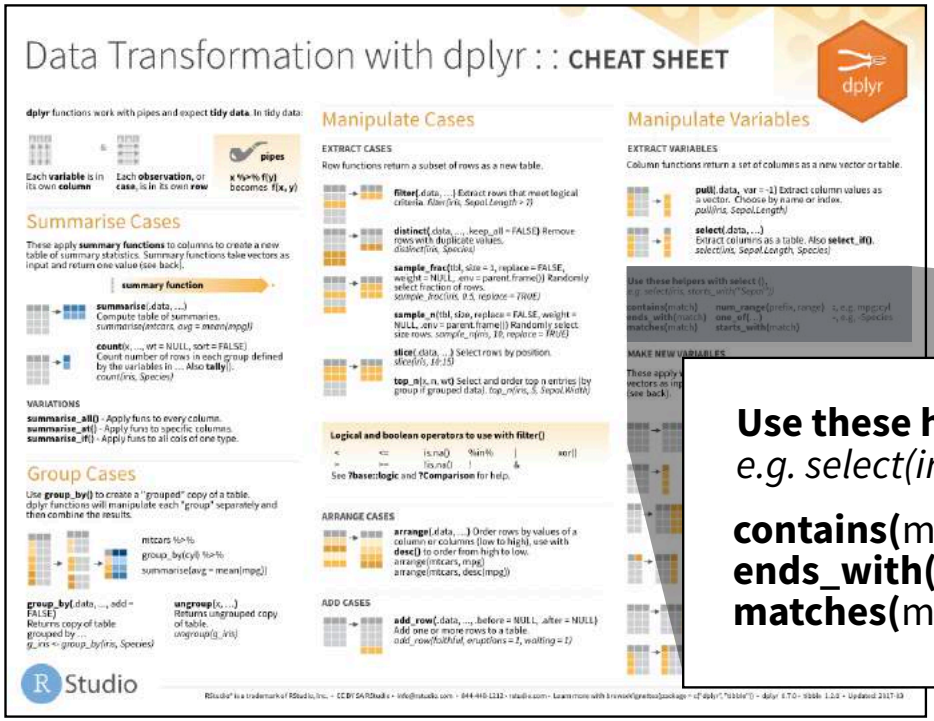

Use these helpers with select (),
e.g. select(iris, starts_with("Sepal"))

contains(match**)**	**num_range(**prefix, range**)**	**:**, e.g. mpg:cyl
ends_with(match**)**	**one_of(**…**)**	**-**, e.g, -Species
matches(match**)**	**starts_with(**match**)**	

Qual destas não seleciona as colunas **name** e **n**?

```
select(babynames, -c(year, sex, prop))
```

```
select(babynames, name:n)
```

```
select(babynames, starts_with("n"))
```

```
select(babynames, ends_with("n"))
```

Qual destas não seleciona as colunas **name** e **n**?

```
select(babynames, -c(year, sex, prop))
```

```
select(babynames, name:n)
```

```
select(babynames, starts_with("n"))
```

```
select(babynames, ends_with("n"))
```

Como isolar as observações de interesse?

	year	sex	name	n	prop
1	1880	F	Mary	7065	0.0724
2	1880	F	Margar	1578	0.0162
3	1880	F	Martha	1040	0.0107
4	1880	F	Marie	471	0.00483
5	1880	F	Maria	125	0.00128
1	1881	F	Mary	6919	0.0700
2	1881	F	Margar	1658	0.0168
3	1881	F	Martha	1044	0.0106
4	1881	F	Marie	499	0.00505
5	1881	F	Maria	120	0.00121
	1881	M	Gideon	7	0.0001

year	sex	name	n	prop
1880	F	Maria	125	0.00128
1881	F	Maria	120	0.00121
…	…	Maria	…	…

filter()

Extrair observações (linhas) de acordo com critérios lógicos

```
filter(.data, … )
```

tabela de dados a transformar

um ou mais testes de lógica (que serão avaliados linha a linha)

filter()

Extrair observações (linhas) de acordo com critérios lógicos

```
filter(babynames, name == “Maria")
```

babynames

year	sex	name	n	prop
1880	F	Mary	7065	0.0724
1880	F	Margaret	1578	0.0162
1880	F	Martha	1040	0.0107
1880	F	Marie	471	0.00483
1880	F	Maria	125	0.00128
1881	F	Mary	6919	0.0700

year	sex	name	n	prop
1880	F	Maria	125	0.00128
1881	F	Maria	120	0.00121
…	…	Maria	…	…

filter()

Extrair observações (linhas) de acordo com critérios lógicos

```
filter(babynames, name == “Maria")
```

babynames

year	sex	name	n	prop
1880	F	Mary	7065	0.0724
1880	F	Margaret	1578	0.0162
1880	F	Martha	1040	0.0107
1880	F	Marie	471	0.00483
1880	F	Maria	125	0.00128
1881	F	Mary	6919	0.0700

= serve para definir opções etc.

== para testes de igualdade
(TRUE ou FALSE)

Testes de lógica

`x < y`	Menor que
`x > y`	Maior que
`x == y`	Igual a
`x <= y`	Menor ou igual a
`x >= y`	Maior ou igual a
`x != y`	Não é igual a
`x %in% y`	Pertence a

O que significa NA?

1 **"1"** **"one"** **NA**

Qual é o resultado de:

1 == 1

Qual é o resultado de:

1 == 1

TRUE

Qual é o resultado de:

1 == NA

Qual é o resultado de:

1 == NA

NA

Qual é o resultado de:

NA == NA

Qual é o resultado de:

NA == NA

NA

Qual é o resultado de:

is.na(NA)

TRUE

Testes de lógica

?Comparison

`x < y`	Menor que
`x > y`	Maior que
`x == y`	Igual a
`x <= y`	Menor ou igual a
`x >= y`	Maior ou igual a
`x != y`	Não é igual a
`x %in% y`	Pertence a
`is.na(x)`	Valor não disponível
`!is.na(x)`	Valor existe

Aplique a função *filter* aos dados *babynames* para extrair:

- As observações onde **prop** é maior ou igual a 0.08
- As observações de crianças chamadas José

```
filter(babynames, prop >= 0.08)
#    year   sex    name      n       prop
# 1  1880     M    John  9655 0.08154630
# 2  1880     M William  9531 0.08049899
# 3  1881     M    John  8769 0.08098299
```

```
filter(babynames, name == “Jose")
    year sex   name      n     prop
   <dbl> <chr> <chr> <dbl>    <dbl>
 1  1880 M     Jose     84 0.000709
 2  1881 M     Jose     76 0.000702
 3  1882 M     Jose     95 0.000778
 4  1883 M     Jose     74 0.000658
```

1. `=` em vez de `==`

```
filter(babynames, name = "Jose")
filter(babynames, name == “Jose")
```

2. Esquecer aspas

```
filter(babynames, name == Jose)
filter(babynames, name == “Jose")
```

3. Caracteres especiais

```
filter(babynames, name == “José”)
filter(babynames, name == “Jose")
```

filter()

Extrai observações que cumpram todos os critérios fornecidos

```
filter(babynames, name == “Maria", year == 1880)
```

babynames

year	sex	name	n	prop
1880	F	Mary	7065	0.0724
1880	F	Margaret	1578	0.0162
1880	F	Martha	1040	0.0107
1880	F	Marie	471	0.00483
1880	F	Maria	125	0.00128
1881	F	Mary	6919	0.0700

year	sex	name	n	prop
1880	F	Maria	125	0.00128

filter(!is.na())

Remover observações com dados em falta

```
filter(x, !is.na(x2))
```

x

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

x1	x2
A	1
D	3

filter()

Extrai observações que cumpram todos os critérios fornecidos

```
filter(babynames, name == "Maria" & year == 1880)
```

babynames

year	sex	name	n	prop
1880	F	Mary	7065	0.0724
1880	F	Margaret	1578	0.0162
1880	F	Martha	1040	0.0107
1880	F	Marie	471	0.00483
1880	F	Maria	125	0.00128
1881	F	Mary	6919	0.0700

year	sex	name	n	prop
1880	F	Maria	125	0.00128

Operadores lógicos

?base::Logic

`a & b`	e
`a | b`	ou
`xor(a,b)`	ou … ou
`!a`	não é
`( )`	agrupar testes

x >= 2 & x < 3

TRUE & TRUE

TRUE

Atenção

3. Testes lógicos de dois lados (intervalos) não funcionam

```
filter(babynames, 10 < n < 20)
filter(babynames, 10 < n, n < 20)
```

4. Juntar vários testes (em vez de usar %in%)

```
filter(babynames, n == 5 | n == 6 | n == 7 | n == 8)
filter(babynames, n %in% c(5, 6, 7, 8))
```

arrange()

Ordenar do mais pequeno para o maior

```
arrange(.data, …)
```

variáveis a usar para ordenação
(por ordem de prioridade)

arrange()

Ordenar do mais pequeno para o maior

```
arrange(babynames, n)
```

babynames

year	sex	name	n	prop
1880	M	John	9655	0.0815
1880	M	William	9532	0.0805
1880	M	James	5927	0.0501
1880	M	Charles	5348	0.0451
1880	M	Garrett	13	0.0001
1881	M	John	8769	0.081

year	sex	name	n	prop
1880	M	Garrett	13	0.0001
1880	M	Charles	5348	0.0451
1880	M	James	5927	0.0501
1881	M	John	8769	0.081
1880	M	William	9532	0.0805
1880	M	John	9655	0.0815

desc()

Ordenar do maior para o mais pequeno

```
arrange(babynames, desc(n))
```

babynames

year	sex	name	n	prop
1880	M	John	9655	0.0815
1880	M	William	9532	0.0805
1880	M	James	5927	0.0501
1880	M	Charles	5348	0.0451
1880	M	Garrett	13	0.0001
1881	M	John	8769	0.081

year	sex	name	n	prop
1880	M	John	9655	0.0815
1880	M	William	9532	0.0805
1881	M	John	8769	0.081
1880	M	James	5927	0.0501
1880	M	Charles	5348	0.0451
1880	M	Garrett	13	0.0001

Qual é o nome mais raro?

E o mais frequente?

```
arrange(babynames, n, prop)
#      year   sex         name     n          prop
#   1  2007     M        Aaban     5 2.259872e-06
#   2  2007     M      Aareon      5 2.259872e-06
#   3  2007     M        Aaris     5 2.259872e-06
#   4  2007     M          Abd     5 2.259872e-06
#   5  2007     M   Abdulazeez     5 2.259872e-06
#   6  2007     M    Abdulhadi     5 2.259872e-06
#   7  2007     M   Abdulhamid     5 2.259872e-06
#   8  2007     M   Abdulkadir     5 2.259872e-06
#   9  2007     M Abdulraheem     5 2.259872e-06
# 10  2007     M   Abdulrahim     5 2.259872e-06
# … with 1,924,655 more rows
```

```
arrange(babynames, desc(n))
#      year   sex    name     n       prop
#  1   1947     F   Linda 99680 0.05483609
#  2   1948     F   Linda 96211 0.05521159
#  3   1947     M   James 94763 0.05102057
#  4   1957     M Michael 92726 0.04238659
#  5   1947     M  Robert 91646 0.04934237
#  6   1949     F   Linda 91010 0.05184281
#  7   1956     M Michael 90623 0.04225479
#  8   1958     M Michael 90517 0.04203881
#  9   1948     M   James 88588 0.04969679
# 10   1954     M Michael 88493 0.04279403
# … with 1,924,655 more rows
```

Mini-teste

Qual o nome de menino mais popular em 2015?

```
boys_2015 <- filter(babynames, year == 2015, sex == "M")
boys_2015 <- select(boys_2015, name, n)
boys_2015 <- arrange(boys_2015, desc(n))
boys_2015
```

```r
boys_2015 <- filter(babynames, year == 2015, sex == "M")
boys_2015 <- select(boys_2015, name, n)
boys_2015 <- arrange(boys_2015, desc(n))
boys_2015
```

```
arrange(select(filter(babynames, year == 2015,
  sex == "M"), name, n), desc(n))
```

sintaxe dplyr de manipulação de dados

Todas as funções têm como primeiro argumento uma tabela de dados e devolvem outra como resultado.

```
filter(.data, … )
```

Operador pipe %>%

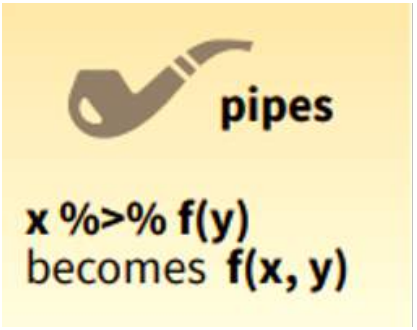

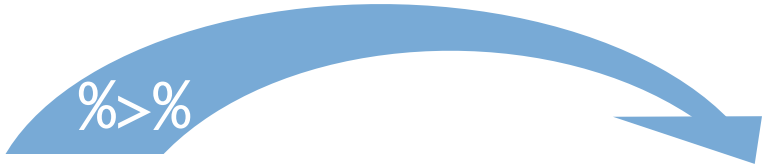


```
babynames    %>%    filter(_____, n == 99680)
```

Passa resultado da esquerda à função da direita, para o seu primeiro argumento. Experimente:

```
filter(babynames, n == 99680)
babynames %>% filter(n == 99680)
```

Pipes

```
babynames
boys_2015 <- filter(babynames, year == 2015, sex == "M")
boys_2015 <- select(boys_2015, name, n)
boys_2015 <- arrange(boys_2015, desc(n))
boys_2015
```

```
babynames %>%
  filter(year == 2015, sex == "M") %>%
  select(name, n) %>%
  arrange(desc(n))
```

Atalho de teclado para %>%

Ctrl + Shift + M (Windows)

e para <-

Alt + - (Windows)

Qual o nome de menina mais popular em 2015?

```
babynames %>%
  filter(year == 2017, sex == "F") %>%
  select(name, n) %>%
  arrange(desc(n))
#    name          n
#   1 Emma      19738
#   2 Olivia    18632
#   3 Ava       15902
#   4 Isabella  15100
#   5 Sophia    14831
#   6 Mia       13437
#   7 Charlotte 12893
#   8 Amelia    11800
#   9 Evelyn    10675
## … with 20,170 more rows
```

Reproduzir o gráfico

1. Filtrar dados para conter apenas as “Marias"
2. Selecionar apenas as colunas necessárias para o gráfico
3. Construir gráfico de linhas com **year** no eixo do x and **prop** no eixo dos y

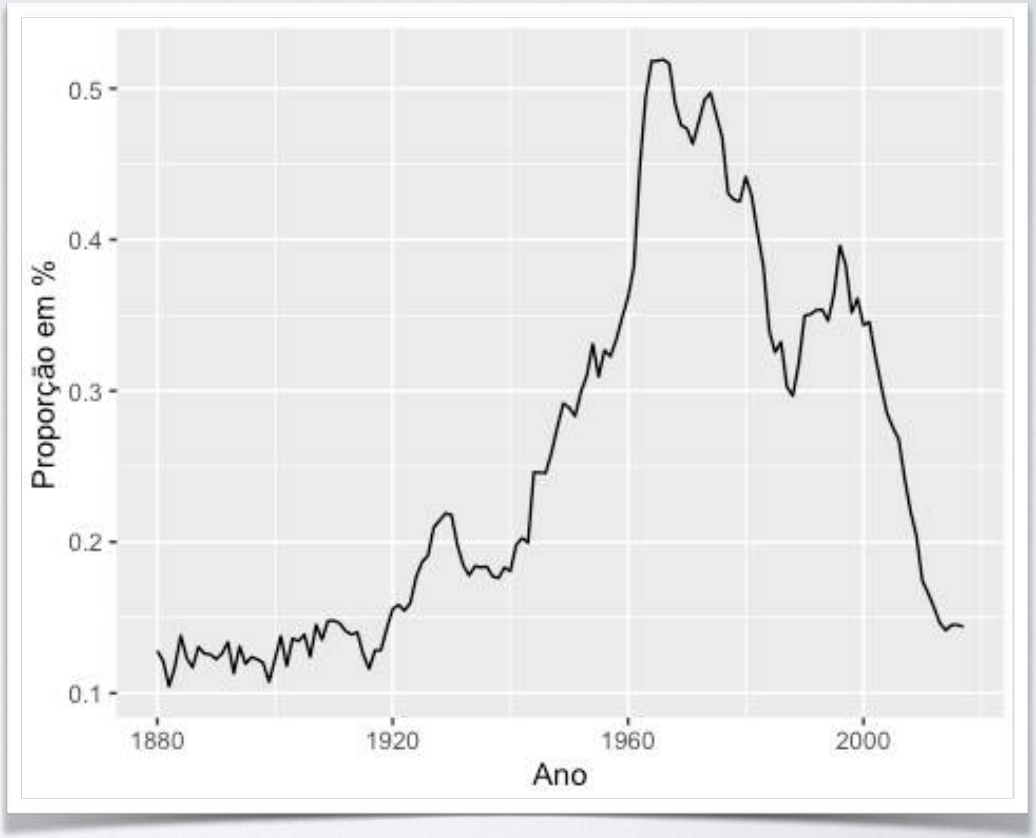

```
babynames %>%
  filter(name == "Maria", sex == “F") %>%
  select(year, prop) %>%
  ggplot() +
    geom_line(mapping = aes(year, prop * 100)) +
    labs(y = 'Proporção em %', x = 'Ano')
```

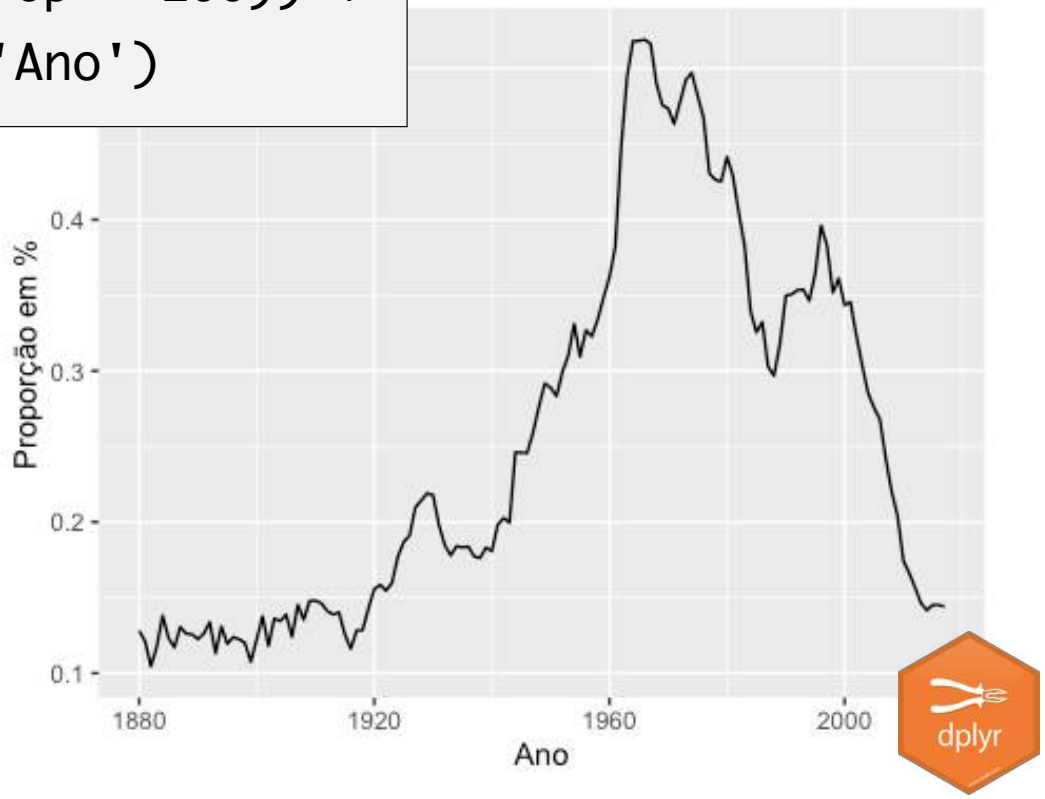

```
babynames %>%
  filter(name == “Maria") %>%
  ggplot() +
    geom_point(mapping = aes(year, prop))
```

Sem filtrar na variável SEX

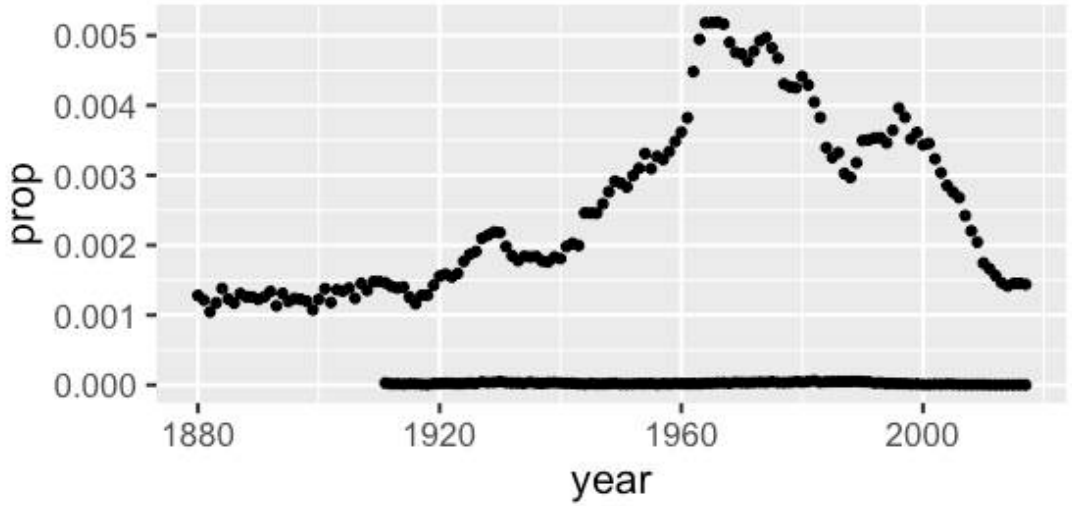

dplyr

```
babynames %>%
  filter(name == “Maria") %>%
  ggplot() +
    geom_line(mapping = aes(year, prop))
```

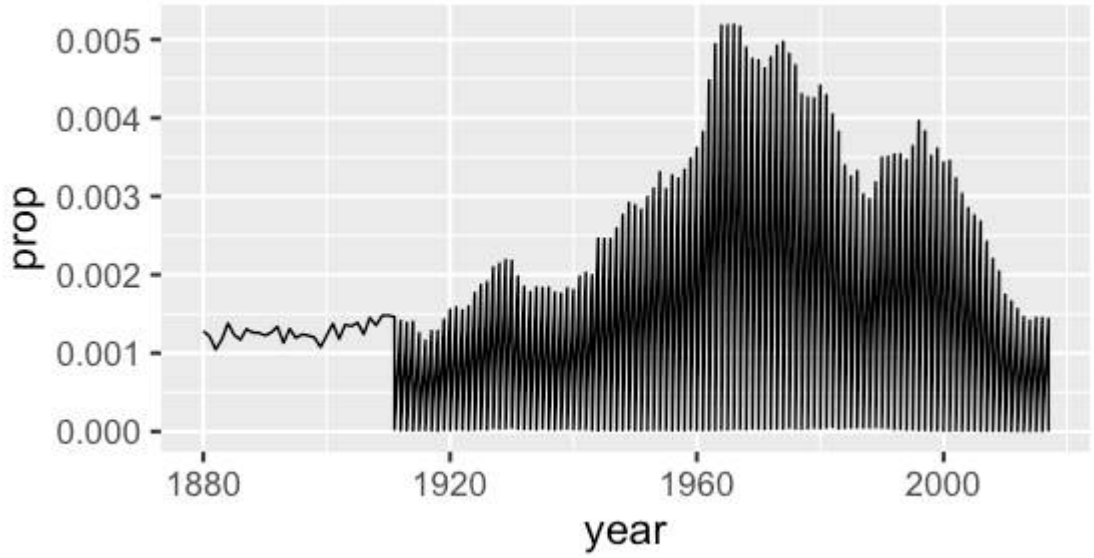

```
babynames %>%
  filter(name == “Maria") %>%
  ggplot() +
    geom_line(mapping = aes(year, prop, color = sex))
```

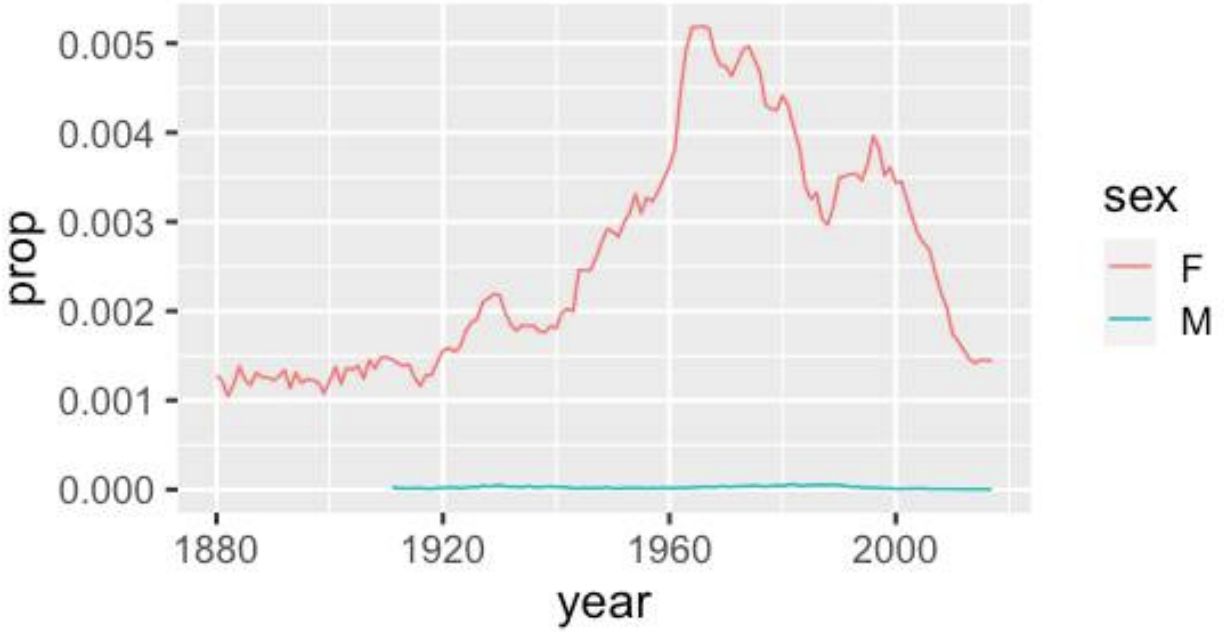

```
babynames %>% filter(name == "Michael") %>%
  ggplot() +
    geom_line(mapping = aes(year, prop)) +
    facet_wrap(~ sex)
```

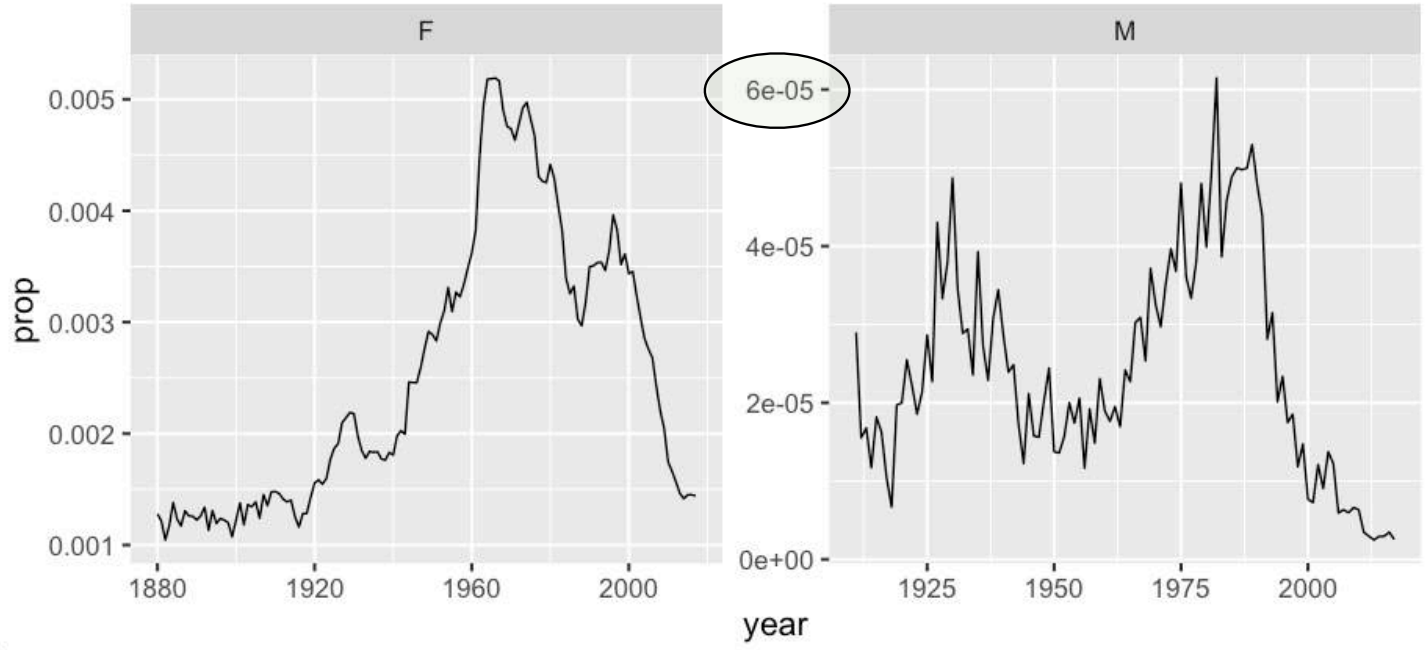

Obrigado
e bom fim-de-semana!

luis.morais@novasbe.pt